Web Mining: Übung 3

Lösungsvorschlag

TECHNISCHE UNIVERSITÄT DARMSTADT

Aufgabe 1:
Einteilung der Testdaten

TECHNISCHE UNIVERSITÄT DARMSTADT

- Verwendeter Testdatensatz: Co-training Experiments for COLT 98
  `http://www.cs.cmu.edu/afs/cs.cmu.edu/project/theo-51/www/co-training/data/`
- Testdaten sind in Unterordnern sortiert:
  Art/Kategorie/VolleURL
- Art kann „fulltext“ oder „inlinks“
- „fulltext“: HTML-Dateien
- „inlinks“: Link-Text(e), die auf die Seiten verwiesen haben.
  Beispiel: `<a href=VolleURL>Link-Text</a>`
- Zur einfacheren Verarbeitung soll die Ordnerhierarchie entfallen und die Informationen in den Dateinamen übernommen werden.

Aufgabe 1:
BASH: Neusortierung/Entfernung der Hierarchie
Teil 1: Die dunklen Zeichen

TECHNISCHE UNIVERSITÄT DARMSTADT

- Mit einem Bash-Skript soll die Hierarchie flach gezogen werden
- Das Namensschema der Dateien soll lauten:
  fulltext|inlinks $\underbrace{---\text{-}--}_{\text{Trenner}}$ Kategorie $\underbrace{---\text{-}--}_{\text{Trenner}}$ VolleURL
- Die URL soll dabei außerdem angepasst werden:
  - Doppelpunkte werden entfernt, weil sich Windows daran stört
  - `http://www.` wird ersetzt, um die URLs zu verkürzen. Windows stört sich auch an langen Dateipfaden
- Am Ende sehen die Dateinamen so aus:
  $\underbrace{\textit{fulltext}}_{\textit{Art}}--\underbrace{\textit{course}}_{\textit{Kategorie}}--\underbrace{\textit{BEG}}_{\textit{http...}}--$ cs.washington.eduˆeducationˆcoursesˆ431ˆ
- Vorteil des Ersetzens gegenüber dem Wegwerfen einzelner Zeichen/Abschnitte: Es gehen keine Informationen verloren. Bei Bedarf kann der gesamte Link wiederhergestellt werden.

Aufgabe 1:
BASH: Neusortierung/Entfernung der Hierarchie
Teil 2: Angriff der Kategorisierung

TECHNISCHE UNIVERSITÄT DARMSTADT

- Die Daten müssen nun noch in Test- und Trainingsdaten eingeteilt werden
- Das Skript wirft für jede Datei die Münze und dokumentiert das Ergebnis ebenfalls im Dateinamen
- Beispiel:
  `test--fulltext--course--BEG--cs.wisc.edu^~dyer^cs766.html`
- Das Ergebnis der Verteilung scheint zufällig und damit brauchbar:

	Training	Test	Summe
course	233	227	460
non-course	802	840	1642
Summe	1035	1067	2102

- Mit dem im weiteren Verlauf verwendeten libsvm lassen sich die Daten zwar einfacher und eleganter in Trainings- und Testdaten einteilen, aber da es nun mal in der Aufgabenstellung stand ...

Aufgabe 2: Aufbereitung der Daten
Dokument zu Wort-Liste
Beispieldokument

TECHNISCHE UNIVERSITÄT DARMSTADT

CSE 590D (Autumn 1995): Transcript-Based Education/WWW

Welcome to the CSE 590D Home Page!

This is the World Wide Web ("the Web" for short) hypermedia document for CSE 590D and contains information about the class. Keep in mind that this document is not static, and that new information will be added from time to time.

Copyright Notice: The material in this course web is subject to copyright. While it may be viewed by the public, it should not be installed at any web site other than the one at the University of Washington.

Reading for October 10 -- G. McCalla: "The Central Importance of Student Modelling in Intelligent Tutoring."

Reading for October 17 -- (presented by Sandi Youngquist)

Meeting of October 23 -- Discussion with Paul Barton-Davis about Internet services.

Reading for October 31 -- C. Laborde and J-M Laborde: "Problem Solving in Geometry: From Microworlds to Intelligent Computer Environments" (presented by Tessa Lau)

Reading for November 7 -- B. Bartels: "Promoting mathematics connections with concept mapping" (plus presentation by Gary Anderson)

No meeting November 14 --

Reading for November 21 --

The readings for this meeting are all online (on the WWW).

Aufgabe 2: Aufbereitung der Daten
Dokument zu Wort-Liste
Reduzierung der Wörter

TECHNISCHE UNIVERSITÄT DARMSTADT

- Text aus dem html-Body wird in Kleinbuchstaben transformiert und an Leerstellen in einzelne Wörter unterteilt
- Emailadressen und URLs, die mit `http[s]://` beginnen, werden entfernt
- Wörter, die auf Satzzeichen, Klammern, Anführungszeichen etc. enden, werden um dieses reduziert
- Ebenso Wörter, die mit Klammern, Anführungszeichen o.ä. beginnen

Beispiel:

`(autumn` wird zu `autumn`
`page!` wird zu `page`
`public,` wird zu `public`
`1995):` wird zu `1995`

Aufgabe 2: Aufbereitung der Daten
Stopwords und Stemming

TECHNISCHE UNIVERSITÄT DARMSTADT

- Die verbliebenen Wörter werden um Stopwords aus einer Liste reduziert
  - Vorher: 381 Wörter
  - Nachher: 231 Wörter
- Anschließendes Stemming der Wörter mit dem Porter Stemmer `https://tartarus.org/martin/PorterStemmer/`
  - Von den 231 Wörtern verbleiben 160 verschiedene Wortstämme

Stemming-Beispiele:

`welcome` $\rightarrow$ `welcom`

`contains` $\rightarrow$ `contain`

`information` $\rightarrow$ `inform`

`added` $\rightarrow$ `ad`

Aufgabe 2: Aufbereitung der Daten
TF-IDF-Vektor

TECHNISCHE UNIVERSITÄT DARMSTADT

- normalisierte TF des Terms t in Dokument d: $\mathrm{tf}(t, d) = \frac{f(t,d)}{\max\{f(w,d):w \in d\}}$
- inv. Document Frequency: $\mathrm{idf}_i = \log \frac{N}{n_i}$
- Gewichtung der einzelnen Wörter: $w_{i,j} = \mathrm{tf}_{i,j} \cdot \mathrm{idf}_i$

Werte der Beispieldatei im Trainingsset:

```
TF-IDF-Vektor:
{'cse': 0.792024194242621 5, '590d': 1.243569187738593 3, 'home':
0.047618296303913 85, 'page': 0.029480629516760913, 'autumn':
0.502504280189381, '1995': 0.153019278021371 6, ...}
```

Aufgabe 2: Aufbereitung der Daten
Sparse-Darstellung

TECHNISCHE UNIVERSITÄT DARMSTADT

- Die 10 häufigsten Wörter nach Dokumenthäufigkeit:
  `[('page', 234), ('comput', 234), ('home', 198), ('scienc', 197), ('univers', 189), ('depart', 149), ('1996', 133), ('inform', 128), ('research', 128), ('system', 127)]`
- Sparse-Format:
  `+1 1:0.029480629516760913 2:0.014740314758380457 3:0.0476182963039138 5:0.026334571412992794 8:0.142473152185994 3`
- Bedeutung:
  - `page` hat eine TF-IDF-Gewichtung von `0.029480629516760913`
  - `comput` hat eine TF-IDF-Gewichtung von `0.014740314758380457`
  - `home` hat eine TF-IDF-Gewichtung von `0.0476182963039138 5`
  - `scienc` ist nicht im Dokument vorhanden
  - `univers` hat eine TF-IDF-Gewichtung von `0.026334571412992794`
  - usw.

Aufgabe 3:
Analyse der erhobenen Daten
Teil 1: Statistische Analyse – Konfusionsmatrix

TECHNISCHE UNIVERSITÄT DARMSTADT

- Trainingsdaten: 151, Testdaten: 152
- Konfusionsmatrix:

		Vorhersage		
		course	non-course	Summe
Kategorie	course (+1)	20	21	41
	non-course (-1)	8	103	111
	Summe	28	124	152

- Accuracy: $A = \frac{TP+TN}{N} = \frac{20+103}{152} \approx 80,92\%$
- Trainingszeit: 0,027884 Sekunden (-t 0 -c 50, 284 Iterationen)
  Testzeit: 0,02458 Sekunden

Aufgabe 3:
Analyse der erhobenen Daten
Teil 1: Statistische Analyse – Baseline

TECHNISCHE UNIVERSITÄT DARMSTADT

- Baseline: Tippt immer auf die am häufigsten vorkommende Kategorie
- Insgesamt sind 231 von 303 Datensätzen non-course (-1)
  Ermittelt mit `cat data.txt | grep '-1' | wc -l`
- In den Trainingsdaten sind 231 - 111 = 120 von 152 Datensätzen non-course
- Die Baseline Konfusionsmatrix sieht also so aus:

		Vorhersage		
		course	non-course	Summe
Kategorie	course (+1)	0	32	32
	non-course (-1)	0	120	120
	Summe	0	152	152

- Accuracy: $A = \frac{TP+TN}{N} = \frac{120}{152} \approx 78,95\%$
- Das trainierte Modell ist mit 80,92% nur wenig besser, was am hohen Anteil von non-course Datensätzen liegt

Aufgabe 3.3: Variation der Feature-Anzahl Genauigkeit

TECHNISCHE UNIVERSITÄT DARMSTADT

- Accuracy fällt zunächst stark ab, nähert sich dann $\approx$ 72% an
- Sinnvoll ist also entweder die Betrachtung von weniger als $\approx$ 50 Features (danach fällt Genauigkeit ab)
- ...oder $\approx$ 600, weil danach die Genauigkeit nicht wesentlich steigt

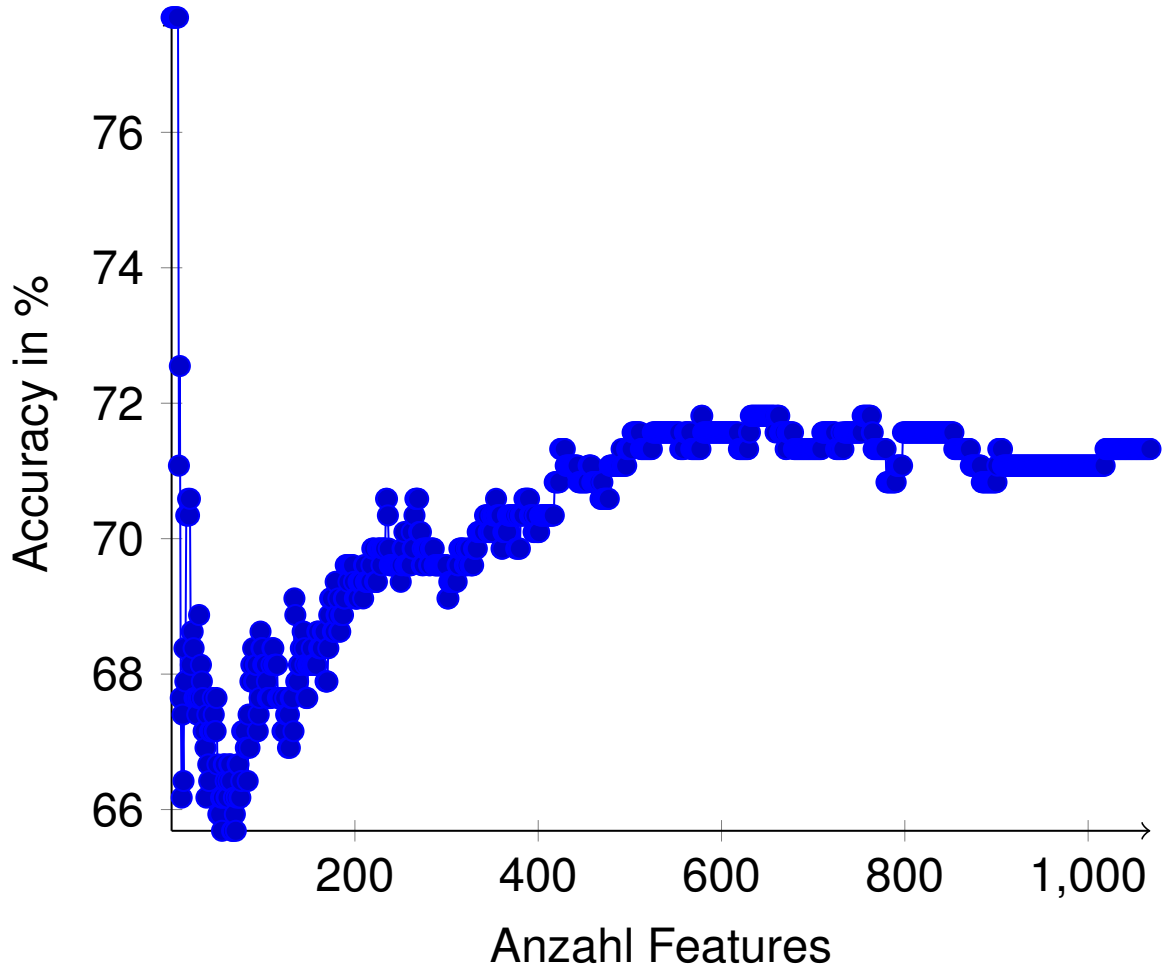

Aufgabe 3.3: Variation der Feature-Anzahl Trainingsdauer

TECHNISCHE UNIVERSITÄT DARMSTADT

- Trainingsdauer steigt von Ausreißern abgesehen etwa linear an
- Selbst mit vielen Features beträgt die Dauer jedoch weniger als eine Sekunde
- $\rightarrow$ Trainingsdauer eher nicht maßgeblich für Wahl der Anzahl

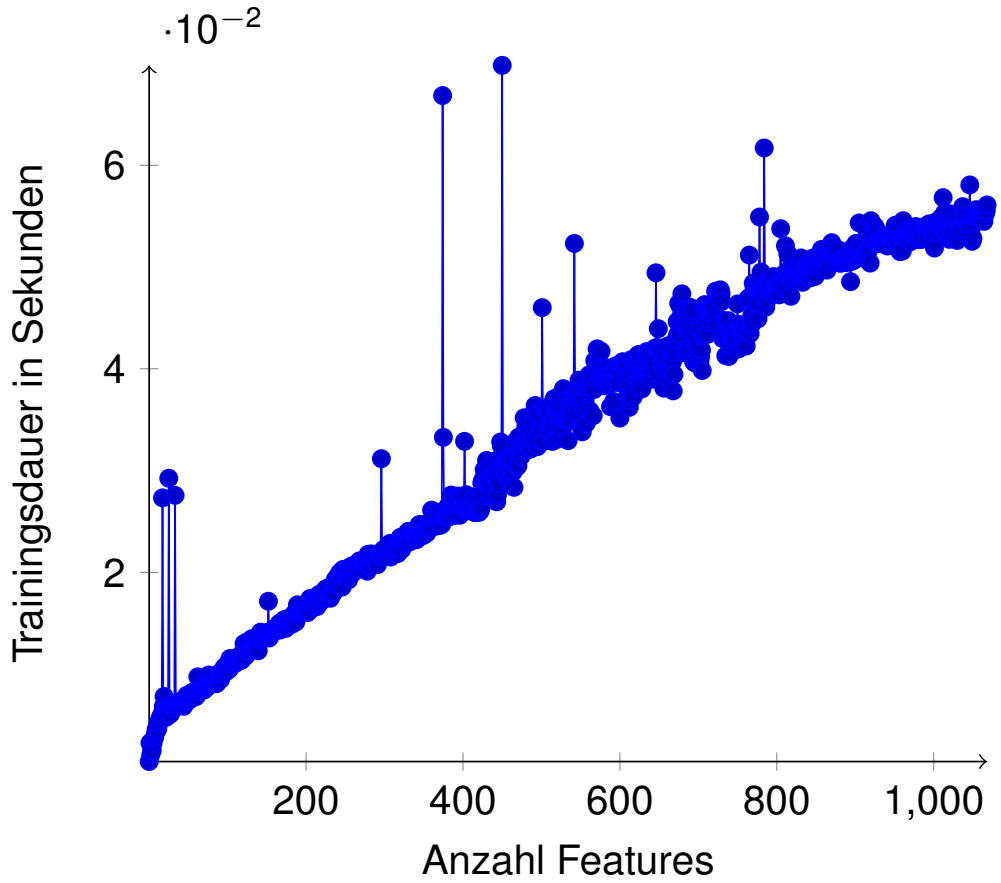

Aufgabe 3.3: Variation der Feature-Anzahl Testdauer

TECHNISCHE UNIVERSITÄT DARMSTADT

- Die Testdauer ist nicht linear
- Abnehmende Grenzrate
- Auch bei vielen Features weit unter einer Sekunde